

Hipóteses nulas dos testes estatísticos bidimensionais de energia, Wasserstein e Bhattacharyya

1 Contexto

Nas comparações realizadas entre a amostra observada (**test**) e a amostra sintética gerada pelo modelo (**df_amstras**) no espaço bidimensional do diagrama BPT ($[\text{NII}]/\text{H}\alpha$ vs. $[\text{OIII}]/\text{H}\beta$), utilizam-se três abordagens para quantificar a similaridade entre as duas distribuições: o teste de energia de Székely e Rizzo, a distância de Wasserstein e o coeficiente de Bhattacharyya. Este documento descreve, de forma didática, a hipótese nula (ou a ausência dela) em cada caso.

2 Teste de energia (Székely & Rizzo)

Hipótese nula. As duas amostras vêm da mesma distribuição de probabilidade, isto é:

$$H_0 : F_{\text{test}} = F_{\text{amostras}},$$

onde F denota a função de distribuição conjunta no plano BPT.

Intuição. A estatística de energia mede uma espécie de “distância elétrica” entre duas nuvens de pontos, comparando as distâncias médias *dentro* de cada grupo com as distâncias médias *entre* os grupos [1, 2]. Quando as duas distribuições coincidem, os pontos de um grupo estão, em média, tão próximos dos pontos do outro grupo quanto dos seus próprios, e a estatística de energia tende a zero.

Inferência. O p-valor é obtido por permutação: os rótulos de grupo (**test** / **amostras**) são embaralhados repetidamente, a estatística de energia é recalculada a cada permutação, e a energia observada é comparada à distribuição empírica resultante. Um p-valor baixo leva à rejeição de H_0 , indicando que as distribuições diferem de forma estatisticamente significativa; um p-valor alto é consistente com a hipótese de que o modelo reproduz bem a distribuição observada.

3 Distância de Wasserstein

Formalmente, a distância de Wasserstein não é um teste de hipótese, mas uma métrica de transporte ótimo entre duas distribuições [3, 5]. No entanto, ao ser combinada com um esquema de permutação, ela passa a admitir uma hipótese nula análoga à do teste de energia.

Hipótese nula. Assumindo o procedimento de permutação,

$$H_0 : F_{\text{test}} = F_{\text{amostras}},$$

de modo que qualquer diferença observada na distância de Wasserstein seria explicável apenas por flutuação amostral.

Intuição. A distância de Wasserstein corresponde ao custo mínimo de trabalho (massa de probabilidade multiplicada pela distância percorrida) necessário para transformar uma distribuição na outra [4, 3]. Diferentemente do teste de energia, ela é sensível não apenas à existência de diferenças, mas também à magnitude e à direção geométrica do deslocamento de massa entre as duas nuvens de pontos.

Inferência. Um valor de 0 indica distribuições idênticas. O p-valor de permutação é calculado com a mesma lógica do teste de energia: embaralham-se os rótulos de grupo, recalcula-se a distância de Wasserstein em cada permutação, e compara-se com o valor observado.

4 Coeficiente e distância de Bhattacharyya

Ausência de hipótese nula formal. Ao contrário dos dois testes anteriores, o coeficiente de Bhattacharyya não constitui um teste de hipótese estatística com p-valor associado [6, 7]. Trata-se de uma medida descritiva de *sobreposição* entre duas densidades de probabilidade estimadas via KDE (*kernel density estimation*) bidimensional, sem uma distribuição nula ou procedimento de permutação subjacente.

Definição. Dadas duas densidades estimadas $p(x, y)$ e $q(x, y)$ no plano BPT, o coeficiente de Bhattacharyya é definido como

$$BC = \iint \sqrt{p(x, y) q(x, y)} dx dy,$$

e a distância correspondente é

$$D_B = -\ln(BC).$$

Interpretação.

- $BC = 1$ ($D_B = 0$): sobreposição total entre as densidades.
- $BC = 0$ ($D_B \rightarrow \infty$): nenhuma sobreposição entre as densidades.

Assim, o coeficiente de Bhattacharyya responde à pergunta “o quanto as duas densidades se sobrepõem?”, enquanto os testes de energia e de Wasserstein respondem, respectivamente, a “as duas amostras podem ser consideradas estatisticamente indistinguíveis?” e “qual o custo de transporte entre as duas distribuições, e esse custo é maior do que o esperado ao acaso?”.

5 Resumo comparativo

Método	Pergunta respondida	Tem p-valor?	Referência
Teste de energia	As nuvens de pontos são estatisticamente indistinguíveis?	Sim (permutação)	[1, 2]
Wasserstein	Qual o custo de deslocamento de massa entre as distribuições, e é maior que o esperado ao acaso?	Sim (permutação)	[3, 4]
Bhattacharyya	Quanto as densidades (KDE) se sobrepõem?	Não (medida descritiva)	[6]

Tabela 1: Comparação entre os três métodos de comparação de distribuições bidimensionais no diagrama BPT.

Referências

- [1] Székely, G. J., & Rizzo, M. L. (2004). *Testing for equal distributions in high dimension*. InterStat, 5(16.10), 1–6.
- [2] Székely, G. J., & Rizzo, M. L. (2013). *Energy statistics: A class of statistics based on distances*. Journal of Statistical Planning and Inference, 143(8), 1249–1272. <https://doi.org/10.1016/j.jspi.2013.03.018>
- [3] Villani, C. (2009). *Optimal Transport: Old and New*. Grundlehren der mathematischen Wissenschaften, vol. 338. Springer-Verlag, Berlin Heidelberg. <https://doi.org/10.1007/978-3-540-71050-9>
- [4] Kantorovich, L. V. (1942). *On the translocation of masses*. Doklady Akademii Nauk SSSR, 37(7–8), 227–229.
- [5] Rubner, Y., Tomasi, C., & Guibas, L. J. (2000). *The Earth Mover’s Distance as a metric for image retrieval*. International Journal of Computer Vision, 40(2), 99–121. <https://doi.org/10.1023/A:1026543900054>
- [6] Bhattacharyya, A. (1943). *On a measure of divergence between two statistical populations defined by their probability distributions*. Bulletin of the Calcutta Mathematical Society, 35, 99–109.
- [7] Kailath, T. (1967). *The divergence and Bhattacharyya distance measures in signal selection*. IEEE Transactions on Communication Technology, 15(1), 52–60. <https://doi.org/10.1109/TCOM.1967.1089532>